Procesamiento y Optimización de Consultas

Ejercicios Simples



2017

Pasos para resolver un ejercicio de optimización

- Entender la consulta
- Pasar de SQL a Algebra Relacional
- Armar árbol canónico
- Aplicar heurísticas algebraicas
- Armar plan de ejecución estimando costos
- Calcular costos

Resumen de Costos

Tipo de archivo / índice	Costo de exploración completa	Costo de búsqueda por igualdad (A = k)	Costo de búsqueda por rango $\left(k_1 \mathrel{<=} A \mathrel{<=} k_2\right)$
Heap file	$\mathbf{B}_{\mathbf{R}}$	B_R	$\mathbf{B}_{\mathbf{R}}$
Sorted file	B_R	$\log_2(B_R) + \lceil T' / FB_R \rceil$	$\log_2(B_R) + \lceil T' / FB_R \rceil$
Índice B+ clustered sobre A	-	$X_I + \lceil T' / FB_R \rceil$	$X_I + \lceil T' / FB_R \rceil$
Índice B+ unclustered sobre A	-	$X-1+\lceil T'/FB_1\rceil+T'$	$X-1+\lceil T'/FB_1\rceil+T'$
Índice hash estático sobre A	-	MBxB _i + T'	-

- T' es la cantidad de tuplas que cumplen con el criterio de la búsqueda
- FBRI es el factor de bloqueo del archivo
- FB_I es el factor de bloqueo del índice I
- MBxB_I es la cantidad máxima de bloques de un bucket

3 / 19

Datos

Idea de la clase

Calcular el costo de consultas pequeñas y simples, con un mismo esquema, cambiando de entorno para ver cómo influyen en los accesos a disco.

Esquema a utilizar

Medico(mld, nombre, especialidad, fechalngreso)

Datos

- tamaño de bloque: 4096 bytes
- longitud de cada campo: 128 bytes
- cantidad de tuplas: 1000

Algunos cálculos:

- **longitud tupla M:** $L_M = 128$ bytes \times 4(registros) = 512 bytes
- factor de bloqueo de M:

$$\textit{FB}_{\textit{M}} = \lceil \textit{tam_bloque} / \textit{L}_{\textit{M}} \rceil = 4096 \textit{bytes} / 512 \textit{bytes} = 8 \textit{tuplas} / \textit{bloque}$$

- cantidad de tuplas: $T_M = 1000 tuplas$
- cantidad de bloques:

$$B_M = \lceil T_M/FB_M \rceil = \lceil 1000 tuplas/8 tuplas/bloque \rceil = 125 bloques$$

(DC - UBA) Optimización 2017 5 / 19

```
SELECT * FROM Médico M
WHERE "1/1/90" < fechalngreso
AND fechalngreso < "1/1/91"
```

```
SELECT * FROM Médico M
WHERE "1/1/90" < fechalngreso
AND fechalngreso < "1/1/91"
```

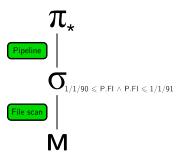
En álgebra relacional:

$$\pi_*(\sigma_{1/1/90} < fechalogreso < 1/1/91 (M))$$

(DC - UBA) Optimización 2017 6 / 19

$$\pi_*(\sigma_{1/1/90} < fechalogreso < 1/1/91 (M))$$

Árbol canónico con su plan de ejecución:



(DC - UBA) Optimización 2017 7 / 19

• La relación M está organizada internamente como un HeapFile.

(DC - UBA) Optimización 2017 8 / 19

• La relación M está organizada internamente como un HeapFile. Por lo tanto sus registros están desordenados.

- La relación M está organizada internamente como un HeapFile. Por lo tanto sus registros están desordenados.
- Entonces para ver el costo de una selección por rango hay que recorrer el archivo completo linealmente (file scan).

- La relación M está organizada internamente como un HeapFile. Por lo tanto sus registros están desordenados.
- Entonces para ver el costo de una selección por rango hay que recorrer el archivo completo linealmente (file scan).
- Costo de búsqueda: $B_M = 125$ bloques.

Datos:

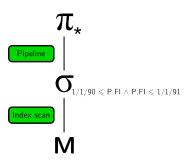
- Misma consulta.
- Costo de acceso al índice de 3 bloques.
- Indice sobre el atributo fechalngreso.
- \bullet Asumimos que entre el '1/1/90' y el '1/1/91' ingresaron 200 médicos.

(DC - UBA) Optimización 2017 9 / 19

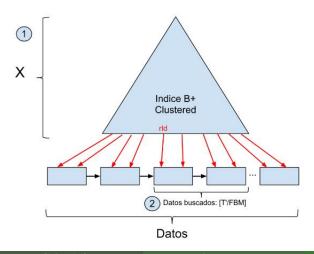
Datos:

- Misma consulta.
- Costo de acceso al índice de 3 bloques.
- Indice sobre el atributo fechalngreso.
- Asumimos que entre el $^{\prime}1/1/90^{\prime}$ y el $^{\prime}1/1/91^{\prime}$ ingresaron 200 médicos.

Como tenemos un índice que coincide con la clave de búsqueda cambia el plan de ejecución:



Costos? Recordemos que...



Pasos a seguir para calcular el costo:

Pasos a seguir para calcular el costo:

• usamos el índice clustered sobre fechalngreso,

Pasos a seguir para calcular el costo:

- usamos el índice clustered sobre fechalngreso,
- recorremos el índice en busca del primer valor que cumpla con el criterio de seleccíon, bajando niveles en el árbol hasta llegar a la hoja donde se encuentra el puntero al primer bloque de datos (costo: 3 bloques),

(DC - UBA) Optimización 2017 11 / 19

Pasos a seguir para calcular el costo:

- usamos el índice clustered sobre fechalngreso,
- recorremos el índice en busca del primer valor que cumpla con el criterio de seleccíon, bajando niveles en el árbol hasta llegar a la hoja donde se encuentra el puntero al primer bloque de datos (costo: 3 bloques),
- leemos en orden (los datos están ordenados físicamente de acuerdo a fechalngreso) (costo: $\lceil T'/FB_M \rceil = [200 \text{ tuplas/8 tuplas/bloque}] =$ **25 bloques**,

(DC - UBA) Optimización 2017 11 / 19

Pasos a seguir para calcular el costo:

- usamos el índice clustered sobre fechalngreso,
- recorremos el índice en busca del primer valor que cumpla con el criterio de seleccíon, bajando niveles en el árbol hasta llegar a la hoja donde se encuentra el puntero al primer bloque de datos (costo: 3 bloques),
- leemos en orden (los datos están ordenados físicamente de acuerdo a fechalngreso) (costo: $\lceil T'/FB_M \rceil = [200 \text{ tuplas/8 tuplas/bloque}] =$ **25 bloques**,
- costo total: $\lceil T'/FB_M \rceil + X$ o sea **28 bloques**

(DC - UBA) Optimización $2017 ext{ } 11 ext{ } / ext{ } 19$

```
SELECT *
FROM Médico M
WHERE especialidad = "traumatología"
```

Datos del ejercicio:

- índice HashTable sobre el atributo especialidad,
- el $MBxB_i$ = cantidad máxima de bloques que ocupa un bucket del índice i (basado en hashing) es 4
- asumimos que hay 100 traumatólogos

```
SELECT *
FROM Médico M
WHERE especialidad = "traumatología"
```

Datos del ejercicio:

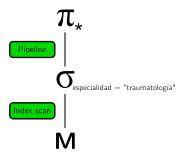
- índice HashTable sobre el atributo especialidad,
- el $MBxB_i$ = cantidad máxima de bloques que ocupa un bucket del índice i (basado en hashing) es 4
- asumimos que hay 100 traumatólogos

Pasamos la consulta a álgebra relacional:

$$\pi_*(\sigma_{especialidad}="traumatologia"(M))$$

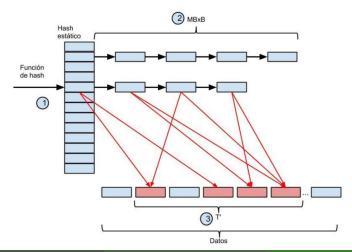
$$\pi_*(\sigma_{especialidad}="traumatologia"(M))$$

Árbol canónico:



(DC - UBA) Optimización 2017 13 / 19

La tabla de hash era:



(DC - UBA) Optimización 2017 1

Pasos a seguir para calcular el costo:

Pasos a seguir para calcular el costo:

• identificar el bucket correspondiente (asumimos costo 0),

(DC - UBA) Optimización <u>2017 15 / 19</u>

Pasos a seguir para calcular el costo:

- identificar el bucket correspondiente (asumimos costo 0),
- recorrer todos los bloques del bucket para encontrar los punteros que se corresponden con las tuplas que coinciden con la clave buscada: MBxBi en peor caso (costo 4),

(DC - UBA) Optimización 2017 15 / 19

Pasos a seguir para calcular el costo:

- identificar el bucket correspondiente (asumimos costo 0),
- recorrer todos los bloques del bucket para encontrar los punteros que se corresponden con las tuplas que coinciden con la clave buscada: MBxBi en peor caso (costo 4),
- acceder tantos bloques de datos como tuplas busquemos, para lo cual hay que leer todos los bloques apuntados por el bucket. Peor caso: cada bloque apunta a un bloque nuevo (costo 100),

Pasos a seguir para calcular el costo:

- identificar el bucket correspondiente (asumimos costo 0),
- recorrer todos los bloques del bucket para encontrar los punteros que se corresponden con las tuplas que coinciden con la clave buscada: MBxBi en peor caso (costo 4),
- acceder tantos bloques de datos como tuplas busquemos, para lo cual hay que leer todos los bloques apuntados por el bucket. Peor caso: cada bloque apunta a un bloque nuevo (costo 100),
- costo total: 104

Si tenemos de nuevo la consulta del primer ejercicio y el índice hash?

```
SELECT *
```

FROM Médico M

WHERE "1/1/90" < fechaIngreso AND fechaIngreso < "1/1/91"

(DC - UBA) Optimización 2017 16 / 19

Si tenemos de nuevo la consulta del primer ejercicio y el índice hash?

```
FROM Médico M
WHERE "1/1/90" < fechaIngreso AND fechaIngreso < "1/1/91"
```

El índice no sirve, hay que recorrer el archivo completo. El índice hash solo sirve para búsquedas por igualdad.

Índice Hash y Rango

Para usar el ínidice por hash habría que tener todos los valores de búsqueda y en general podrían ser infinitos.

(DC - UBA) Optimización 2017 16 / 19

Tenemos la consulta:

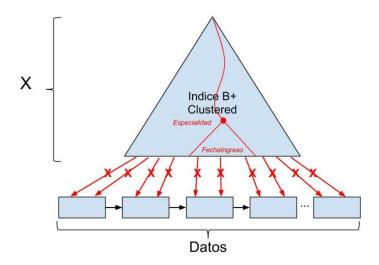
```
SELECT fechaIngreso
FROM Médico M
WHERE especialidad = "traumatología"
```

Índice

Árbol B^+ clustered sobre los atributos: < **Especialidad, Fechalngreso** >, Altura del árbol: 4 bloques

Atención: el índice está físicamente ordenado por especialidad, y adentro de ese atributo por fechalngreso.

Gráficamente:



Pasos a seguir:

Pasos a seguir:

• leemos 4 bloques (la altura del árbol)

Pasos a seguir:

- leemos 4 bloques (la altura del árbol)
- luego debemos leer N hojas (cantidad de fechas ingreso que cumplen con especialidad 'traumatología'). Esto puede aumentarnos la cantidad de bloques en memoria. Por simplicidad para los cálculos, asumimos que se lee 1 hoja.

(DC - UBA) Optimización 2017 19 / 19

Pasos a seguir:

- leemos 4 bloques (la altura del árbol)
- luego debemos leer N hojas (cantidad de fechas ingreso que cumplen con especialidad 'traumatología'). Esto puede aumentarnos la cantidad de bloques en memoria. Por simplicidad para los cálculos, asumimos que se lee 1 hoja.
- costo total: 4